

LAPORAN
UJIAN TENGAH SEMESTER - RAG
DATA ENGINNERING



Oleh :

Kelompok 6:

Jimli Dwi Assiddiqi (244311015),

Muhsyam Fahriel Septiansyah (244311021),

Satriyo Wicaksono Yunan Mubarak (244311027)

JURUSAN TEKNIK
PROGRAM STUDI REKAYASA PERANGKAT LUNAK
POLITEKNIK NEGERI MADIUN
2026

A. Deskripsi Sistem dan Stack yang Dipilih

Proyek PadiBot merupakan implementasi sistem tanya-jawab cerdas berbasis dokumen yang menerapkan arsitektur Retrieval-Augmented Generation (RAG) dengan memfokuskan pemrosesan informasi pada domain pertanian. Sistem ini dirancang untuk membaca dan mengekstraksi data dari dokumen lokal, yang kemudian disimpan ke dalam vector database menggunakan ChromaDB melalui proses indexing. Ketika menerima kueri, sistem akan melakukan proses retrieval untuk mendapatkan konteks informasi yang paling relevan. Konteks tersebut selanjutnya diproses oleh Large Language Model (LLM) Groq untuk menggeneralisasi jawaban yang akurat dan berlandaskan fakta dari dokumen sumber. Pengembangan aplikasi ini dibangun menggunakan framework LangChain untuk menyusun pipeline data engineering secara utuh dan mengintegrasikannya dengan Streamlit sebagai antarmuka pengguna interaktif.

Berdasarkan deskripsi proyek di atas, pengembangan sistem ini memanfaatkan beberapa pustaka (library) utama. Berikut adalah rincian dan alasan pemilihan masing-masing pustaka yang digunakan:

1. LangChain

LangChain dipilih karena menyediakan framework terstruktur untuk membangun sistem RAG secara efisien dan modular. Pustaka ini mempermudah pembangunan pipeline RAG (seperti proses indexing dan querying) dengan menyediakan komponen siap pakai, mulai dari document loader, text splitter, hingga integrasi vector store. Hal ini secara signifikan mengurangi kompleksitas penulisan kode dari awal.

2. ChromaDB (Vector Database)

ChromaDB diimplementasikan sebagai vector database karena sifatnya yang sederhana, ringan, dan efektif untuk menyimpan serta melakukan pencarian embedding secara lokal tanpa memerlukan server terpisah. Pustaka ini juga terintegrasi langsung dengan LangChain, menjadikannya sangat ideal untuk proyek skala kecil-menengah maupun kebutuhan akademik.

3. Sentence-Transformers (HuggingFace Embeddings)

Pustaka ini berfungsi untuk mengubah teks menjadi representasi numerik (embedding) yang mutlak diperlukan dalam proses similarity search pada arsitektur RAG. Penggunaan model seperti all-MiniLM-L6-v2 dipilih karena memiliki kinerja yang ringan, cepat, dan dapat dijalankan secara offline tanpa bergantung pada API eksternal.

4. Groq (LLM API)

Groq dipilih sebagai penyedia Large Language Model (LLM) karena menawarkan performa tinggi dengan waktu respons yang jauh lebih cepat dibandingkan API lainnya dalam menghasilkan jawaban berbasis konteks. Dukungannya terhadap model bahasa canggih seperti LLaMA, serta aksesibilitasnya, sangat menunjang proses pengembangan dan demonstrasi.

5. PyPDF (PDF Loader)

PyPDF digunakan sebagai alat untuk memuat dan mengekstrak isi dokumen berekstensi PDF. Pustaka ini berperan penting dalam proses penarikan teks dari file laporan pengguna untuk kemudian dijadikan sebagai sumber data (konteks) utama dalam sistem RAG.

6. Python-dotenv

Pustaka ini digunakan untuk mengelola variabel lingkungan (environment variables) secara aman dan terstruktur. Penyimpanan konfigurasi sensitif seperti API key dan path direktori di dalam file .env dirancang untuk menghindari praktik hardcode di dalam kode program, sehingga keamanan sistem lebih terjamin.

B. Tabel Evaluasi

No	Pertanyaan	Jawaban Sistem RAG	Jawaban Ideal / Referensi	Skor Relevansi (1-5)
1	Sebutkan angka produksi panen padi di Kabupaten Madiun pada bulan Januari tahun 2018 dan bulan Maret tahun 2018, lalu bandingkan apakah terjadi peningkatan atau penurunan?	Berikut adalah angka produksi panen padi di Kabupaten Madiun pada bulan Januari tahun 2018 dan bulan Maret tahun 2018: Januari 2018: 812.18 ton, Maret 2018: 94455.58 ton. Untuk membandingkan, kita hitung selisih antara kedua angka tersebut: $94455.58 - 812.18 = 93643.40$. Karena angka produksi panen padi pada bulan Maret tahun 2018 (94455.58 ton) lebih besar daripada pada bulan Januari tahun 2018 (812.18 ton), maka terjadi peningkatan produksi panen padi sebesar 93643.40 ton.	Produksi padi di Kabupaten Madiun pada Januari 2018 adalah 812,18 ton dan pada Maret 2018 adalah 94.455,58 ton. Terjadi peningkatan produksi sebesar 93.643,40 ton.	5
2	Berapa produksi padi di Kabupaten Blitar pada bulan Januari tahun 2021?	Produksi padi Kabupaten Blitar bulan Januari tahun 2021 adalah 10497.28 ton.	Produksi padi Kabupaten Blitar pada bulan Januari 2021 adalah 10.497,28 ton.	5
3	Berapa produksi padi di Kabupaten Ngawi pada bulan Februari tahun 2021?	Produksi padi di Kabupaten Ngawi pada bulan Februari tahun 2021 adalah 36572.31 ton.	Produksi padi di Kabupaten Ngawi pada bulan Februari 2021 adalah 36.572,31 ton.	5
4	Apakah produksi padi di Kabupaten Blitar meningkat dari Januari ke Maret tahun 2021?	Untuk mengetahui apakah produksi padi di Kabupaten Blitar meningkat dari Januari ke Maret tahun 2021 kita perlu mencari data produksi padi di Kabupaten Blitar pada bulan Januari dan Maret tahun 2021. Namun tidak ada data produksi padi di Kabupaten Blitar pada bulan Januari tahun 2021 dalam konteks yang diberikan. Oleh karena itu saya tidak dapat memberikan jawaban yang akurat. Jika Anda memiliki data tambahan atau konteks yang lebih luas, saya dapat membantu Anda menganalisis data tersebut.	Ya, terjadi peningkatan/penurunan produksi. Produksi Januari 2021 adalah 10.497,28 ton dan Maret 2021 adalah [Nilai Produksi Maret]. (Nilai disesuaikan dengan dataset)	1
5	Apakah produksi padi di Kabupaten Blitar meningkat dari Januari ke Maret tahun 2018?	Untuk mengetahui apakah produksi padi di Kabupaten Blitar meningkat dari Januari ke Maret tahun 2018 kita perlu mencari data produksi padi di Kabupaten Blitar pada bulan Januari dan Maret tahun 2018. Namun tidak ada data produksi padi di Kabupaten Blitar pada bulan Januari tahun 2018 dalam konteks yang diberikan.	Ya, terjadi peningkatan produksi. Produksi padi di Kabupaten Blitar pada bulan Januari 2018 adalah 43.155,75 ton dan pada bulan Maret 2018 meningkat menjadi 124.636,36 ton.	1
6	Faktor apa saja yang mempengaruhi perubahan produksi padi di Jawa Timur berdasarkan data yang tersedia?	Berdasarkan data yang tersedia faktor yang mempengaruhi perubahan produksi padi di Jawa Timur adalah: El Nino. El Nino menyebabkan turunnya luas panen padi sehingga produksi padi	Faktor utama meliputi dampak El Nino, perubahan metode sensus ke Kerangka Sampel Area (KSA) pada 2018, serta variabel cuaca dan lingkungan seperti suhu dan curah hujan.	5

		mengalami penurunan Penggunaan metode Kerangka Sampel Area (KSA): Pada tahun 2018 penghitungan luas panen komoditas padi mulai menggunakan metode KSA sehingga produksi dan luas panen komoditas padi tidak dapat dibandingkan dengan luas panen dan produksi pada tahun sebelumnya. Pengaruh cuaca: Cuaca yang tidak mendukung dapat mempengaruhi produksi padi seperti pada tahun 2021 yang mengalami penurunan produksi padi karena cuaca yang tidak mendukung. Pengaruh faktor lingkungan: Faktor lingkungan seperti kelembaban suhu dan curah hujan dapat mempengaruhi produksi padi. Namun perlu diingat bahwa data yang tersedia tidak menyebutkan secara spesifik faktor-faktor yang mempengaruhi perubahan produksi padi di Jawa Timur.		
7	Apakah produksi padi di Kabupaten Magetan meningkat dari bulan Januari ke bulan Maret tahun 2019	Produksi padi di Kabupaten Magetan pada bulan Januari tahun 2019 adalah 1764.91 ton, sedangkan pada bulan Maret tahun 2019 adalah 73480.11 ton. Jadi, produksi padi di Kabupaten Magetan meningkat dari bulan Januari ke bulan Maret tahun 2019.	Ya, produksi meningkat. Angka pada Januari 2019 adalah 1.764,91 ton, yang kemudian naik menjadi 73.480,11 ton pada Maret 2019.	4
8	Bagaimana gambaran umum kondisi produksi padi di Jawa Timur berdasarkan data yang tersedia?	Berdasarkan data yang tersedia, produksi padi di Jawa Timur terbesar berada di Kabupaten Lamongan, diikuti Kabupaten Ngawi dan Kabupaten Bojonegoro. Kontribusi produksi padi Provinsi Jawa Timur sebesar 17,44% terhadap produksi padi nasional.	Produksi padi tertinggi disumbang oleh Kabupaten Lamongan, Ngawi, dan Bojonegoro. Secara keseluruhan, Jawa Timur menyumbang 17,44% terhadap total produksi padi nasional.	5
9	Apakah produksi atau produktivitas padi di Jawa Timur mengalami fluktuasi dalam beberapa tahun terakhir?	Ya, berdasarkan data yang tersedia, produktivitas padi di Jawa Timur mengalami fluktuasi dalam beberapa tahun terakhir. Pada tahun 2018, produktivitas tertinggi mencapai 5,76 ton per hektar, sedangkan pada tahun 2020, produktivitas terendah mencapai 5,60 ton per hektar.	Ya, terjadi fluktuasi. Puncak produktivitas tercatat pada 2018 (5,76 ton/hektar), dan titik terendah terjadi pada 2020 (5,60 ton/hektar).	5
10	Berapa produksi padi Kabupaten Ngawi bulan Januari tahun 2021?	Produksi padi Kabupaten Ngawi bulan Januari tahun 2021 adalah 4448.31 ton.	Produksi padi Kabupaten Ngawi pada Januari 2021 adalah 4.448,31 ton.	5

C. Analisis dan Saran

Analisis

Berdasarkan hasil pengujian terhadap 10 sampel pertanyaan, sistem PadiBot memperoleh rata-rata skor sebesar **4,1 dari 5,0**, yang menunjukkan bahwa sistem telah memiliki performa yang baik dalam mengimplementasikan arsitektur *Retrieval-Augmented Generation (RAG)* pada domain data statistik pertanian. Sistem menunjukkan keunggulan dalam melakukan ekstraksi fakta dan peringkasan informasi, khususnya pada pertanyaan yang membutuhkan data numerik tunggal. Dalam kasus tersebut, model mampu memberikan jawaban yang akurat, relevan, serta tidak menghasilkan informasi yang bersifat halusinasi.

Namun demikian, masih terdapat kelemahan pada pertanyaan yang bersifat komparatif, yaitu ketika sistem diminta untuk membandingkan data antar periode waktu. Pada beberapa kasus, retriever belum mampu mengambil beberapa konteks yang relevan secara bersamaan, sehingga LLM tidak memiliki informasi yang cukup untuk melakukan analisis perbandingan, meskipun data sebenarnya tersedia di dalam dokumen. Hal ini menunjukkan bahwa permasalahan utama terletak pada proses retrieval, bukan pada kemampuan model bahasa.

Saran

Untuk meningkatkan performa sistem, khususnya dalam menangani pertanyaan komparatif, diperlukan beberapa perbaikan pada tahap retrieval dan pengolahan data. Penyetelan parameter retrieval seperti nilai TOP_K dapat dilakukan agar lebih banyak konteks relevan dapat dikirim ke model. Selain itu, proses chunking perlu disempurnakan agar data yang saling berkaitan tidak terpisah di dalam vector database. Penggunaan strategi retrieval yang lebih adaptif, seperti kombinasi antara similarity search dan MMR, juga dapat membantu meningkatkan kualitas konteks yang diperoleh. Dengan perbaikan tersebut, diharapkan sistem mampu memberikan jawaban yang lebih lengkap dan akurat, terutama untuk pertanyaan yang membutuhkan analisis antar data.